

基于隐式漂移曝光的 联合鲁棒层次对比学习方法

HCL+IDS 技术方法章节说明

面向安卓恶意软件概念漂移的主动持续学习

技术文档 · 2026年7月

内容提要

安卓恶意软件检测模型部署后会持续面对恶意家族演化、行为策略变化和应用生态更新，由此产生明显的时间概念漂移。在真实场景中，逐月标注全部新应用具有较高成本，因此需要在有限标注预算下主动发现具有代表性的漂移样本，并利用少量标注数据持续更新检测模型。

本文在层次化对比学习模型HCL的基础上，引入隐式漂移曝光机制IDS。该方法首先利用局部伪损失识别与历史表示结构不一致的候选样本；随后围绕新标注样本构建由当前样本、历史相似样本和历史相反类别样本组成的时间曝光集合；在此基础上，通过代理编码器搜索能够放大曝光任务损失、同时保持表示变化受限的参数扰动；最后在一次优化器更新中联合累积普通HCL梯度和扰动状态下的曝光鲁棒梯度。

核心思想

不在离散安卓特征空间中直接合成应用，而是在由真实漂移样本及其历史关系定义的曝光集合上，搜索任务相关的编码器不利参数方向，使模型在有限标注条件下学习对潜在分布变化更加稳定的决策边界。

符号说明

符号	含义
D_t	第 t 个月到达的安卓应用集合
x_i, y_i, c_i	应用特征、良恶性二分类标签与家族标签
$h_{\{\theta_e\}}, g_{\{\theta_c\}}$	特征编码器与二分类器
Q_t	第 t 月主动查询并获得真实标签的样本集合
E_t	由新标注样本及历史关系样本构成的曝光集合
$\lambda, \gamma, \rho, \beta$	扰动尺度、特征约束权重、EMA衰减系数和鲁棒损失权重

目录

内容提要	1
符号说明	1
3.1 问题定义	3
3.2 方法总体框架	3
3.3 HCL基础检测模型	3
3.3.1 模型结构	3
3.3.2 层次化距离损失	4
3.3.3 分类损失与基础目标	4
3.4 基于局部伪损失的主动样本选择	4
3.5 基于时间关系的漂移曝光构建	5
3.5.1 曝光三元组	5
3.5.2 类别平衡与批次组织	5
3.6 受约束的隐式参数扰动	6
3.6.1 代理编码器初始化	6
3.6.2 高损失扰动搜索	6
3.6.3 逐层归一化	6
3.6.4 EMA扰动平滑	7
3.7 普通损失与鲁棒损失的联合优化	7
3.8 月度持续适应算法	8
3.9 训练稳定机制与实现设置	8
3.10 方法特点与技术边界	9
3.11 与HCL基线的区别	10

3.1 问题定义

设安卓应用按照月份连续到达，第 t 个月的应用集合表示为：

$$D_t = \{(x_i, y_i, c_i)\}_{i=1}^{N_t} \quad (1)$$

其中， $x_i \in \mathbb{R}^d$ 表示应用的静态特征， $y_i \in \{0, 1\}$ 表示良性或恶意二分类标签， c_i 表示恶意软件家族标签。对于良性应用，可将其统一视作一个特殊家族。

初始检测模型使用历史数据 D_0 训练。随着恶意软件的行为模式、家族构成和特征分布不断变化，后续月份的数据分布 $P_t(X, Y)$ 逐渐偏离初始训练分布 $P_0(X, Y)$ ，使固定模型产生性能衰减。本文研究有限标注预算下的安卓恶意软件持续学习问题：每个月仅允许从当前候选池中查询 K 个样本的真实标签，并利用这些样本更新模型。

给定连续月份数据流 $\{D_1, D_2, \dots, D_T\}$ ，本文希望在控制累计标注成本的同时，提高模型在未来月份上的 F1，并重点降低恶意样本漏检率 FNR。该问题同时包含时间分布变化、主动样本选择和月度模型更新三个相互耦合的过程。

3.2 方法总体框架

本文方法建立在层次化对比学习模型 HCL 之上，并引入隐式漂移曝光机制 IDS。整体框架由四个核心模块构成：

- 基于局部伪损失的漂移样本选择：发现与历史表示结构冲突的高价值候选样本。
- 基于时间关系的曝光三元组构建：显式关联当前漂移样本、历史相似样本和历史相反类别样本。
- 受约束的对抗参数扰动搜索：在编码器参数空间搜索任务相关的不利变化方向。
- 普通损失与曝光鲁棒损失联合优化：在同一次参数更新中兼顾总体分布学习与漂移适应。



在第 t 个月，系统使用当前模型对候选样本进行检测并选择 K 个样本请求标签。新标注样本被迫加到历史训练集尾部，同时作为当月曝光集合的中心。模型重训练时，普通批次学习累计训练集的总体分布，曝光批次则用于搜索不利参数方向并计算鲁棒梯度。更新后的模型继续处理下一个月份，由此形成逐月闭环。

3.3 HCL基础检测模型

3.3.1 模型结构

基础检测模型由特征编码器 h_{θ_e} 和二分类器 g_{θ_c} 组成。编码器将高维安卓特征映射到低维表示空间，MLP 分类器根据编码表示输出良性和恶意概率：

$$z_i = h_{\theta_e}(x_i), p_i = g_{\theta_c}(z_i) \quad (2)$$

模型完整参数记为 $\theta = \{\theta_e, \theta_c\}$ 。编码器末层不使用激活函数，以保留表示空间的距离关系；分类器通过Softmax输出二分类概率。

3.3.2 层次化距离损失

HCL同时利用二分类标签和恶意家族标签组织表示空间。对于任意样本 i ，根据样本关系构造四类集合：

集合	关系	优化目标
B_i	与样本 i 同为良性	控制良性簇的内部离散程度
S_i	与样本 i 属于同一恶意家族	直接压缩同家族表示距离
O_i	同为恶意但属于不同家族	控制恶意类别整体分布范围
N_i	与样本 i 的良恶性标签相反	扩大良性与恶意表示间隔

$$d_{ij} = \|z_i - z_j\|_2^2 \quad (3)$$

令 $d_{i,A}^{avg}$ 表示样本 i 与集合 A 中样本的平均距离， m 表示距离间隔，则层次化距离损失可概括为：

$$L_{HD} = \text{mean}_i \{ [d_{i,B_i}^{avg} - m]_+ + [d_{i,O_i}^{avg} - m]_+ + d_{i,S_i}^{avg} + [2m - d_{i,N_i}^{avg}]_+ \} \quad (4)$$

其中 $[a]_+ = \max(a, 0)$ 。该目标以二分类边界为外层约束，以恶意家族关系为内层结构，使编码空间同时保留良恶性可分性和家族级局部结构。

3.3.3 分类损失与基础目标

$$L_{CE} = -\text{mean}_i \{ y_i \log p_i^{(1)} + (1 - y_i) \log p_i^{(0)} \} \quad (5)$$

$$L_{HCL} = L_{HD} + \alpha L_{CE} \quad (6)$$

其中 α 为二分类损失权重。距离损失负责塑造层次表示空间，分类损失负责直接优化良恶性判别结果。

3.4 基于局部伪损失的主动样本选择

仅依赖输出概率的传统不确定性采样难以反映候选样本与历史表示结构之间的冲突。当前HCL实现使用局部伪损失作为样本查询分数，从表示空间和预测标签两个角度评估候选样本。

首先计算候选样本及历史训练样本的归一化编码表示，并通过KDTree为每个候选样本查找k个最近历史邻居。随后，以当前模型预测结果作为候选样本的伪二分类标签，将该样本与其历史近邻组成局部批次，并计算样本级HCL损失：

$$s(x) = L_{HCL}(x, N_k(x), y^p) \quad (7)$$

$$Q_t = \text{TopK}_{x \in D_t} s(x) \quad (8)$$

局部伪损失越大，说明候选样本与历史近邻在类别预测或表示关系上越不一致。系统按照 $s(x)$ 降序选择前K个样本并请求真实标签。

实现口径

本方法中的高不确定样本并非简单按照Softmax熵或最大预测概率选择，而是按照局部伪损失排序。因此在论文中宜称为“局部结构不确定性”或“局部伪损失驱动的主动查询”。

3.5 基于时间关系的漂移曝光构建

3.5.1 曝光三元组

获得当月新标注集合 Q_t 后，本文不将其作为普通独立样本直接微调，而是围绕每个当前样本构建时间曝光三元组：

$$T_i = (x_i^c, x_i^s, x_i^o) \quad (9)$$

角色	样本来源	作用
当前样本 x^c	当月主动查询并获得真实标签的样本	提供最新漂移信息
历史相似样本 x^s	优先选择同家族历史样本；不存在时退化为同二分类类别	连接新分布与历史类内结构
历史相反样本 x^o	从二分类标签相反的历史样本中选择	保留良性与恶意决策边界

$$E_t = \bigcup_{x_i^c \in Q_t} \{x_i^c, x_i^s, x_i^o\} \quad (10)$$

3.5.2 类别平衡与批次组织

主动学习可能在某些月份集中选择某一类别，直接构造曝光集合会进一步放大类别偏置。当新标注集合同时包含良性和恶意样本时，本文分别从两类当前样本中选择相同数量的曝光中心。各三元组在批处理时按照角色重新排列为全部当前样本、全部历史相似样本和全部历史相反样本。

三元组的准确含义

对HCL而言，三元组用于组织结构化曝光数据，而不是直接调用传统Triplet Loss。曝光批次进入HCL后，仍根据整个批次中的二分类标签和家族标签构造两两关系掩码，并计算集合式层次距离损失。

3.6 受约束的隐式参数扰动

3.6.1 代理编码器初始化

本文建立与当前HCL模型结构相同的代理模型，其参数记为 θ^p 。每次扰动搜索前，将当前模型的完整状态复制到代理模型。搜索过程只由代理模型的编码器优化器更新 θ_e^p ，分类头保持为当前模型分类头的复制结果，从而将不利变化集中在特征表示阶段。

$$\theta^p \leftarrow \theta \quad (11)$$

3.6.2 高损失扰动搜索

对于曝光批次 E ，首先使用当前模型计算归一化参考表示；随后在代理模型上计算归一化表示，并使用两者的均方误差约束表示变化：

$$z_i^{\text{ref}} = \text{Norm}(h_{\theta_e}(x_i)), z_i^p = \text{Norm}(h_{\theta_e^p}(x_i)) \quad (12)$$

$$L_{\text{con}} = \text{mean}_{x_i \in E} \|z_i^p - z_i^{\text{ref}}\|_2^2 \quad (13)$$

代理编码器通过最小化下式搜索能够增大曝光任务损失、但不会造成表示空间无约束偏移的参数方向：

$$L_{\text{search}} = -L_{\text{HCL}}(\theta^p; E) + \gamma L_{\text{con}} \quad (14)$$

负任务损失驱动代理编码器寻找当前模型的薄弱方向，特征距离项则限制该方向仍处于当前表示邻域。当前实现使用一次SGD更新近似求解，不对扰动搜索过程计算二阶梯度。

3.6.3 逐层归一化

$$\delta_l = W_l^p - W_l \quad (15)$$

$$\delta_l^n = [\|W_l\|_2 / (\|\delta_l\|_2 + \epsilon)] \delta_l \quad (16)$$

逐层归一化使扰动幅度与该层原始权重尺度保持一致，避免参数规模较大的层支配整体扰动。当前实现只保存并施加编码器中名称以weight结尾的权重矩阵差异，不扰动偏置项。

3.6.4 EMA扰动平滑

$$\Delta_l^{(r)} = \rho \Delta_l^{(r-1)} + (1-\rho) \delta_l^{n(r)} \quad (17)$$

其中 r 表示当前月度重训练过程中的曝光更新步。EMA用于降低不同曝光批次产生的扰动方向波动。IDS控制器在每个月重新创建，因此该扰动状态默认只在当前月份的重训练内部累积，而不会自动跨月份继承。

3.7 普通损失与鲁棒损失的联合优化

在模型更新阶段，普通训练批次 B 用于维持累计训练集上的整体判别能力，曝光批次 E 用于强化模型对当月漂移关系的鲁棒性。首先在原始参数处计算普通HCL损失：

$$L_{\text{normal}} = L_{\text{HCL}}(\theta; B) \quad (18)$$

然后将平滑后的扰动临时加入编码器权重，其中 λ 控制实际扰动尺度：

$$\theta_e^{\text{adv}} = \theta_e + \lambda \Delta \quad (19)$$

$$L_{\text{robust}} = L_{\text{HCL}}(\theta_e + \lambda \Delta, \theta_c; E) \quad (20)$$

$$L_{\text{joint}} = L_{\text{normal}} + \beta L_{\text{robust}} \quad (21)$$

实现时，系统先清空梯度并反向传播普通损失；之后临时施加编码器扰动，在不清空已有梯度的情况下反向传播 βL_{robust} ；鲁棒梯度计算结束后立即恢复原始编码器参数，执行梯度裁剪，并调用一次优化器更新。

$$\theta \leftarrow \theta - \eta \{ \text{grad}_{\theta} L_{\text{normal}} + \beta \text{grad}_{\theta} L_{\text{robust}} \} \quad (22)$$

虽然扰动只施加在编码器权重上，但曝光鲁棒损失的计算图同时经过编码器和MLP分类头，因此鲁棒损失会为完整HCL模型累积梯度。该联合更新避免了普通目标与鲁棒目标分别执行优化器更新时产生的连续参数覆盖，使两类目标在同一更新步内完成融合。

阶段	参数状态	数据	作用
普通梯度	原始参数 θ	累计训练集普通批次 B	维持总体判别能力
鲁棒梯度	临时参数 $\theta_e + \lambda \Delta$	时间曝光批次 E	适应漂移与不利参数邻域
参数更新	恢复后的原始参数 θ	两部分累积梯度	执行一次联合优化

3.8 月度持续适应算法

输入：初始训练集 D_0 ，月份数据流 $\{D_1, \dots, D_T\}$ ，每月预算 K ，参数 λ 、 γ 、 ρ 、 β 。

```

1 使用 $D_0$ 训练初始HCL模型 $\theta_0$ 。

2 for  $t = 1, 2, \dots, T$  do

3 使用当前模型 $\theta_{t-1}$ 检测第 $t$ 个月样本。

4 为每个候选样本计算局部伪损失 $s(x)$ 。

5 选择得分最高的 $K$ 个样本并获取真实标签，得到 $Q_t$ 。

6 将 $Q_t$ 追加到累计训练集。

7 为 $Q_t$ 中的当前样本构造时间曝光集合 $E_t$ 。

8 使用普通HCL损失预热 $w$ 个重训练轮次。

9 for 普通训练批次 $B$ 及对应曝光批次 $E$  do

10 在代理编码器上最小化 $-L_{HCL} + \gamma L_{con}$ 。

11 计算逐层归一化参数差，并通过EMA更新 $\Delta$ 。

12 在原始参数上反向传播 $L_{normal}$ 。

13 临时施加 $\lambda\Delta$ 并反向传播 $\beta L_{robust}$ 。

14 恢复原始参数，裁剪累积梯度并执行一次优化器更新。

15 end for

16 获得更新后的月度模型 $\theta_t$ 。

17 end for

输出：按月份持续更新的模型序列 $\{\theta_1, \dots, \theta_T\}$ 。

```

3.9 训练稳定机制与实现设置

为降低月度小样本重训练中的梯度波动，当前方法采用预热和梯度裁剪两项稳定机制。预热阶段仅使用普通HCL目标更新模型；当重训练轮次超过预热阈值后，才启动曝光扰动搜索和鲁棒梯度累积。代理编码器搜索和最终联合更新均使用梯度范数裁剪。

参数	当前配置	含义
λ	0.001	归一化编码器权重扰动的实际施加尺度
γ	1.0	扰动搜索中的归一化特征距离约束权重
ρ	0.6	连续曝光更新之间的扰动EMA衰减系数
代理学习率	1.0	代理编码器单步SGD搜索学习率
β	1.0	联合目标中的曝光鲁棒损失权重
曝光批大小	192	结构化曝光样本总批大小，需至少为3
预热轮次	5	前5轮仅执行普通训练，第6轮开始IDS
梯度裁剪	1.0	代理搜索及联合模型更新的梯度范数上限

上述数值属于当前APIGraph实验使用的静态实现配置。论文方法定义应主要说明各参数的功能；具体取值、选择范围和敏感性分析宜在实验设置与参数分析章节中报告。

3.10 方法特点与技术边界

本文方法建立了“主动发现漂移样本-构造时间关系曝光-搜索任务相关不利扰动-联合鲁棒更新”的完整适应链条。与普通历史样本重放、随机参数噪声或单纯困难样本训练相比，其主要区别在于扰动方向由带有时间关系的真实曝光数据驱动。

特点	技术体现
标注针对性	局部伪损失同时利用模型预测和历史近邻关系识别结构冲突样本
时间关系建模	曝光集合连接当前漂移样本、历史相似关系和二分类边界样本
隐式漂移扩展	不直接修改离散安卓特征，而是在编码器参数空间模拟不利变化
扰动可控性	特征约束、逐层归一化和EMA共同限制扰动幅度与波动
优化一致性	普通梯度和曝光鲁棒梯度在一次优化器更新中完成融合

该方法的主要目标是提升有限标签预算和明显时间漂移条件下的适应性能，并不保证在标注预算充足或分布变化较弱时始终产生同等幅度的收益。当新标注数据已经能够充分覆盖当前分布时，过强的曝光鲁棒梯度可能与普通训练梯度产生冲突。因此，预算规模、月份难度以及普通损失与鲁棒损失之间的平衡，是后续实验分析和方法扩展需要重点讨论的边界条件。

3.11 与HCL基线的区别

HCL+IDS并未替换HCL的基础检测器和主动持续学习框架，而是在HCL完成漂移样本查询之后，新增结构化曝光、参数空间扰动和联合鲁棒更新机制。因此，需要区分HCL原有组成与本文相对HCL新增的技术组成。

技术模块	HCL基线	HCL+IDS	相对HCL的属性
编码器与MLP分类器	已有	直接保留	继承
层次距离损失与二分类损失	已有	直接保留	继承
Local Pseudo Loss主动选样	已有	直接保留	继承
逐月查询、扩充训练集并重训	已有	直接保留	继承
时间曝光三元组与类别平衡	无	新增	核心区别
代理编码器高损失扰动搜索	无	新增	核心区别
特征约束、逐层归一化与EMA	无	新增	核心区别
普通损失与鲁棒损失联合更新	无	新增	核心区别
IDS预热与梯度裁剪	无	新增	训练稳定机制

从技术链条看，HCL负责表示学习、局部伪损失选样以及月度重训练；本文新增部分则负责将少量新标注样本转换为具有时间关系的漂移曝光，并利用这些曝光数据构造针对当前模型薄弱方向的鲁棒训练目标。

3.11.1 时间关系驱动的漂移曝光

原始HCL在选择并标注当月样本后，主要将其追加到累计训练集并执行普通重训练。本文进一步围绕每个新标注样本构造“当前样本-历史相似样本-历史相反类别样本”三元组，并在条件允许时对良性和恶性曝光中心进行平衡。

- 当前样本提供最新月份的漂移信息。
- 同家族或同类别历史样本连接新分布与历史类内结构。
- 相反类别历史样本保留良性与恶意之间的决策边界。

因此，该模块并非简单增加历史样本数量，而是显式建立当前分布、历史类内结构和历史分类边界之间的关系。这是本文相对HCL最直接的数据组织区别。

3.11.2 曝光驱动的受约束参数扰动

原始HCL只在当前模型参数上最小化层次距离损失与分类损失。本文额外建立代理编码器，并在曝光集合上搜索能够增大HCL任务损失的参数方向。该搜索同时使用归一化特征距离限制表示变化，避免代理模型偏离当前任务邻域。

得到代理编码器与当前编码器之间的参数差后，本文按照原始权重范数对各层扰动进行归一化，并通过EMA平滑连续曝光批次的扰动方向。由此得到的扰动不是随机噪声，而是由真实漂移样本及其历史关系共同驱动的任务相关不利方向。

3.11.3 普通训练与曝光鲁棒训练的联合优化

原始HCL的月度重训练只计算累计训练集上的普通HCL损失。本文在原始参数上计算普通损失，同时在临时加入编码器扰动的参数状态下计算曝光鲁棒损失，并将两部分梯度在同一次优化器更新中融合。

- 普通梯度用于维持累计历史数据上的整体判别能力。
- 曝光鲁棒梯度用于强化当月漂移关系和不利参数邻域下的稳定性。
- 一次联合更新减少两类目标连续更新时的参数覆盖和优化震荡。

扰动只临时施加于编码器权重矩阵，但鲁棒损失会经过编码器和MLP分类头反向传播，因此最终更新完整HCL模型。预热和梯度裁剪用于稳定这一训练过程，属于必要的实现机制，但不应作为主要方法创新单独强调。

3.11.4 学术归属与方法贡献表述

层次化表示学习、Local Pseudo Loss主动选样和月度持续学习流程属于HCL原有组成。代理参数扰动、逐层归一化和EMA等思想主要借鉴W-DOE。本文的贡献重点应表述为：将分布无关曝光思想改造到安卓恶意软件时间概念漂移场景，设计面向新标注样本的时间曝光三元组，并将普通HCL目标与扰动曝光目标整合为一次联合优化。

建议的论文概括

本文在HCL主动持续学习框架的基础上，引入时间结构化漂移曝光机制，并利用曝光样本搜索受约束的编码器不利参数方向，最终通过普通损失与曝光鲁棒损失的联合优化，提高模型在有限标注预算和时间概念漂移条件下的适应能力。